

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP THÁI NGUYÊN

KHOA ĐIỆN TỬ

BỘ MÔN: CÔNG NGHỆ THÔNG TIN



BÀI TIỂU LUẬN

MÔN HỌC

KHOA HỌC DỮ LIỆU

**ĐỀ TÀI: PHÂN TÍCH HÀNH VI KHÁCH HÀNG &
TỐI ƯU BÁN LẺ THƯƠNG MẠI BẰNG HỌC MÁY
TRÊN TẬP DỮ LIỆU OLIST**

GIÁO VIÊN HƯỚNG DẪN: TS. NGUYỄN VĂN HUY

SINH VIÊN THỰC HIỆN : LƯƠNG HOÀNG VIỆT

MSSV: K225480106073

LỚP : 58.KTP

Thái Nguyên - 2026

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP THÁI NGUYÊN

KHOA ĐIỆN TỬ

BỘ MÔN: CÔNG NGHỆ THÔNG TIN



BÀI TIỂU LUẬN

MÔN HỌC

KHOA HỌC DỮ LIỆU

**ĐỀ TÀI: PHÂN TÍCH HÀNH VI KHÁCH HÀNG &
TỐI ƯU BÁN LẺ THƯƠNG MẠI BẰNG HỌC MÁY
TRÊN TẬP DỮ LIỆU OLIST**

GIÁO VIÊN HƯỚNG DẪN: TS. NGUYỄN VĂN HUY

SINH VIÊN THỰC HIỆN : LƯƠNG HOÀNG VIỆT

MSSV: K225480106073

LỚP : 58.KTP

Thái Nguyên - 2026

Thái Nguyên, ngày 19 tháng 06 năm 2026

PHIẾU GIAO ĐỀ TÀI

Họ tên sinh viên: Lương Hoàng Việt

MSSV: K225480106073

Chuyên ngành : KTPM

Lớp học phần: 58KTP

TÊN ĐỀ TÀI: PHÂN TÍCH HÀNH VI KHÁCH HÀNG & TỐI ƯU BÁN LẺ THƯƠNG MẠI BẰNG HỌC MÁY TRÊN TẬP DỮ LIỆU OLIST

1. Yêu cầu thực hiện:

- Tiền xử lý và Khám phá dữ liệu
- Phân cụm khách hàng
- Dự đoán tỷ lệ rời bỏ

2. Kết quả dự kiến:

- Báo cáo theo mẫu của Khoa và bộ môn
- Github chứa code, link thuyết trình

Ngày giao nhiệm vụ: 07/06/2026

Ngày hoàn thành nhiệm vụ: 21/06/2026

Họ và tên cán bộ hướng dẫn:

BM. CÔNG NGHỆ THÔNG TIN

CÁN BỘ HƯỚNG DẪN

Nguyễn Văn Huy

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Thái Nguyên, ngày....tháng.....năm 2026

GIÁO VIÊN HƯỚNG DẪN

(Ký ghi rõ họ tên)

NHẬN XÉT CỦA GIÁO VIÊN CHẤM

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Thái Nguyên, ngày....tháng.....năm 2026

GIÁO VIÊN CHẤM

(Ký ghi rõ họ tên)

MỤC LỤC

PHIẾU GIAO ĐỀ TÀI	1
DANH MỤC HÌNH ẢNH.....	6
LỜI NÓI ĐẦU.....	7
CHƯƠNG 1: TỔNG QUAN VÀ MÔ TẢ DỮ LIỆU	8
1.1. Đặt vấn đề và Mục tiêu đề tài.....	8
1.1.1. Bối cảnh thương mại điện tử	8
1.1.2. Các thách thức đối với hệ thống bán lẻ	8
1.2. Mô tả tập dữ liệu Olist (Brazilian E-Commerce Public Dataset)	8
1.2.1. Giới thiệu nguồn dữ liệu	8
1.2.2. Sơ đồ mối quan hệ thực thể (ERD)	8
1.2.3. Chi tiết các bảng dữ liệu thành phần.....	9
1.3. Phương pháp nghiên cứu.....	9
CHƯƠNG 2. TIỀN XỬ LÝ VÀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)	12
2.1. Kỹ thuật Tiền xử lý dữ liệu (Data Preprocessing)	12
2.1.1. Chuẩn hóa kiểu dữ liệu (Data Type Casting)	12
2.1.2. Trích lọc dữ liệu hợp lệ	12
2.1.3. Tích hợp dữ liệu (Data Integration).....	12
2.1.4. Xử lý giá trị khuyết thiếu (Missing Values)	12
2.2. Phân tích Khám phá Dữ liệu (Exploratory Data Analysis).....	12
2.2.1. Khám phá Hiệu suất Danh mục Sản phẩm	12
2.2.2. Phân tích Hành vi Giữ chân Khách hàng (Retention Rate)	13
2.2.3. Phân tích Thời điểm Mua sắm (Hotspot Analysis).....	14
2.2.4. Phân bổ Vị trí Địa lý và Thời gian Vận chuyển.....	15
2.2.5. Phân tích Trải nghiệm Khách hàng qua Điểm đánh giá (Review Score)....	16
CHƯƠNG 3. PHÂN CỤM KHÁCH HÀNG BẰNG THUẬT TOÁN K-MEANS	18
3.1. Cơ sở lý thuyết mô hình RFM.....	18
3.1.1. Recency (Khoảng cách mua hàng).....	18
3.1.2. Frequency (Tần suất mua hàng)	18
3.1.3. Monetary (Giá trị chi tiêu).....	18
3.2. Tiền xử lý dữ liệu cho thuật toán K-Means	19
3.2.1. Biến đổi phân phối logarit (Log Transformation).....	19
3.2.2. Chuẩn hóa dữ liệu (Standardization)	19
3.3. Huấn luyện và Đánh giá Mô hình K-Means	20

3.3.1. Thiết lập tham số và Kiểm định định lượng mô hình (Hyperparameters & Model Validation).....	20
3.3.2. Đặc tả chân dung 4 cụm khách hàng (Customer Profiling)	21
3.3.3. Định hướng Chiến lược Cá nhân hóa (Personalization Strategy).....	23
CHƯƠNG 4: DỰ ĐOÁN KHÁCH HÀNG RỜI BỎ BẰNG RANDOM FOREST	25
4.1. Bài toán Dự đoán Rời bỏ (Churn Prediction)	25
4.1.1. Phân tích và tính toán các chỉ số phân loại chuyên sâu (Precision, Recall, F1-Score)	25
4.1.2. Lựa chọn các đặc trưng đầu vào (Features Selection)	25
4.2. Xử lý Mất cân bằng dữ liệu (Imbalanced Data).....	26
4.2.1. Tác hại của dữ liệu mất cân bằng trong máy học.....	26
4.2.2. Áp dụng kỹ thuật sinh mẫu nhân tạo SMOTE.....	27
4.3. Huấn luyện Mô hình Random Forest Classifier.....	28
4.3.1. Cơ sở lý thuyết thuật toán Random Forest	29
4.3.2. Quá trình chia tập dữ liệu (Train/Test Split).....	29
4.3.3. Tiến hành huấn luyện mô hình (Model Training).....	29
4.3.4. Tối ưu hóa Siêu tham số (Hyperparameter Tuning) với GridSearchCV.....	30
4.4. Đánh giá Kết quả và Ứng dụng Thực tiễn	31
4.4.1. Đọc hiểu chi tiết Ma trận nhầm lẫn (Confusion Matrix).....	31
4.4.2. Phân tích Báo cáo Phân loại (Classification Report)	32
4.4.3. Phân tích Chuyên sâu Mức độ đóng góp của Đặc trưng (Feature Importance).....	35
4.4.4. Kết luận về Tiềm năng Ứng dụng Thực tiễn.....	36
KẾT LUẬN.....	37
QR CODE GITHUB.....	39
TÀI LIỆU THAM KHẢO	40

DANH MỤC HÌNH ẢNH

Hình 1.1. Sơ đồ mối quan hệ thực thể (ERD) thu gọn của tập dữ liệu Olist.	9
Hình 1.2. Sơ đồ luồng tổng quan quy trình Khoa học Dữ liệu (Data Science Pipeline)	11
Hình 2.1. Hiệu suất Doanh thu và Số lượng bán của Top 10 Danh mục sản phẩm..	13
Hình 2.2. Cơ cấu phân bổ Khách hàng mua một lần và Khách hàng quay lại	14
Hình 2.3. Ma trận nhiệt (Heatmap) thể hiện Lưu lượng Chốt đơn theo thời gian	15
Hình 2.4. Phân bổ Phương thức Thanh toán tại 5 Bang có Lượng đơn cao nhất	16
Hình 2.5. Tác động của Tình trạng Giao hàng đến Điểm Đánh giá Trung bình.....	17
Hình 3.1. Phương pháp Khuỷu tay (Elbow Method) xác định tham số K tối ưu	20
Hình 3.2. Biểu đồ Phân tán (Scatter Plot) phân cụm Khách hàng theo K-Means	22
Hình 3.3. Thống kê Số lượng Khách hàng phân bổ theo từng Cụm.....	23
Hình 4.1. Sự Mất cân bằng Dữ liệu (Imbalanced Data) của nhãn Rời bỏ	27
Hình 4.2. Sơ đồ biểu diễn cơ sở toán học của thuật toán nội suy sinh mẫu nhân tạo (SMOTE).....	28
Hình 4.3. Ma trận Nhầm lẫn (Confusion Matrix) của mô hình Random Forest.....	32
Hình 4.4. Đường cong ROC và Chỉ số diện tích dưới đường cong (AUC) của Random Forest.	35
Hình 4.5. Mức độ quan trọng của Đặc trưng (Feature Importance).	35
Hình 4.6. Đề xuất Kiến trúc hạ tầng MLOps triển khai hệ thống dự đoán theo thời gian thực.....	37
Hình 5.1. Qr code github.....	39
Bảng 3.1. Bảng Đặc tả Tâm cụm (Centroids)	23
Bảng 4.1. Bảng So sánh Hiệu năng & Triển khai các thuật toán Phân loại.....	28
Bảng 4.2. Bảng Báo cáo Phân loại (Classification Report)	32

LỜI NÓI ĐẦU

Trong bối cảnh bùng nổ của ngành thương mại điện tử hiện nay, việc ra quyết định dựa trên dữ liệu (Data-driven decision making) không chỉ là một lợi thế cạnh tranh mà còn là yếu tố sống còn của mọi doanh nghiệp. Để hiểu rõ hơn về quy trình ứng dụng dữ liệu vào việc định hình chiến lược kinh doanh và tối ưu hóa trải nghiệm người dùng, em đã lựa chọn đề tài: **"Phân tích Hành vi Khách hàng & Tối ưu Bán lẻ Thương mại Điện tử bằng Học máy trên tập dữ liệu Olist"** cho bài tiểu luận môn học này.

Thông qua quá trình nghiên cứu, em đã có cơ hội vận dụng trực tiếp các kiến thức đã tích lũy trong quá trình đào tạo tại Trường Đại học Kỹ thuật Công nghiệp (TNUT) vào việc giải quyết các bài toán thực tiễn. Đề tài tập trung vào việc tiền xử lý khối lượng dữ liệu lớn, khám phá hành vi mua sắm, phân cụm người dùng bằng K-Means và dự đoán rủi ro rời bỏ hệ thống bằng Random Forest.

Em xin gửi lời tri ân sâu sắc và chân thành nhất đến **TS. Nguyễn Văn Huy**. Nhờ những bài giảng sinh động, sự tâm huyết và sự hướng dẫn chuyên môn tận tình của thầy trong suốt quá trình học tập, em đã có nền tảng vững chắc và định hướng rõ ràng để hoàn thành bài báo cáo này.

Mặc dù đã nỗ lực hết sức để triển khai bài làm một cách chu đáo, nhưng do những giới hạn nhất định về mặt thời gian cũng như kinh nghiệm thực tiễn, tiểu luận chắc chắn vẫn còn những thiếu sót. Em rất mong sẽ nhận được những lời nhận xét, góp ý quý báu từ thầy để em có thể tiếp tục trau dồi và hoàn thiện hơn nữa các kỹ năng chuyên môn của mình trong tương lai.

Em xin chân thành cảm ơn!

CHƯƠNG 1: TỔNG QUAN VÀ MÔ TẢ DỮ LIỆU

1.1. Đặt vấn đề và Mục tiêu đề tài

1.1.1. Bối cảnh thương mại điện tử

Thị trường thương mại điện tử đang chứng kiến sự chuyển dịch mạnh mẽ trong hành vi mua sắm của người tiêu dùng cùng với sức ép cạnh tranh ngày càng gay gắt. Điều này bắt buộc các nền tảng bán lẻ không ngừng tối ưu hóa hệ thống vận hành và nâng cao trải nghiệm người dùng để duy trì vị thế trên thị trường.

1.1.2. Các thách thức đối với hệ thống bán lẻ

Trong quá trình vận hành, các hệ thống bán lẻ phải đối mặt với nhiều bài toán hóc búa, điển hình là những khó khăn trong việc xác định các sản phẩm cốt lõi mang lại lợi nhuận cao. Bên cạnh đó, doanh nghiệp cũng chịu tổn thất lớn từ tỷ lệ khách hàng rời bỏ cao, đồng thời phải đối phó với những rủi ro liên quan đến quá trình vận chuyển.

1.1.3. Mục tiêu phân tích và ứng dụng Khoa học Dữ liệu

Để giải quyết triệt để các thách thức trên, đề tài hướng tới mục tiêu ứng dụng toàn diện quy trình Khoa học Dữ liệu (Data Science), bao gồm Phân tích khám phá dữ liệu (EDA) và mô hình hóa Học máy (Machine Learning). Thông qua các phương pháp này, nghiên cứu kỳ vọng rút ra được các quyết định định hướng dữ liệu (Data-driven), giúp doanh nghiệp phát triển chiến lược kinh doanh chính xác và hiệu quả thay vì dựa vào cảm tính.


1.2. Mô tả tập dữ liệu Olist (Brazilian E-Commerce Public Dataset)

1.2.1. Giới thiệu nguồn dữ liệu

Nghiên cứu tiến hành phân tích trên tập dữ liệu thương mại điện tử Olist có nguồn gốc từ nền tảng Kaggle. Đây là tập dữ liệu có quy mô lớn với thông tin của hơn 100.000 đơn hàng, cung cấp một bức tranh toàn cảnh và chân thực về thị trường mua sắm trực tuyến.

1.2.2. Sơ đồ mối quan hệ thực thể (ERD)

Dữ liệu được lưu trữ dưới dạng cơ sở dữ liệu quan hệ, được mô tả rõ nét qua sơ đồ mối quan hệ thực thể (ERD). Sơ đồ này thể hiện chi tiết cách các bảng dữ liệu đơn lẻ liên kết đồng bộ với nhau qua các khóa chính và khóa ngoại, hỗ trợ cho việc truy xuất thông tin phức tạp.



Hình 1.1. Sơ đồ mối quan hệ thực thể (ERD) thu gọn của tập dữ liệu Olist.

1.2.3. Chi tiết các bảng dữ liệu thành phần

Để phục vụ quá trình phân tích đa chiều, nghiên cứu tiến hành khai thác các bảng dữ liệu thành phần sau:

- ❖ Bảng Lịch sử đơn hàng (olist_orders_dataset).
- ❖ Bảng Chi tiết sản phẩm trong đơn (olist_order_items_dataset).
- ❖ Bảng Thông tin khách hàng (olist_customers_dataset).
- ❖ Bảng Danh mục sản phẩm (olist_products_dataset).
- ❖ Bảng Thanh toán (olist_order_payments_dataset).
- ❖ Bảng Đánh giá (olist_order_reviews_dataset).

1.3. Phương pháp nghiên cứu

Để giải quyết triệt để các bài toán kinh doanh đã đặt ra, đề tài áp dụng quy trình Khoa học Dữ liệu (Data Science Pipeline) tiêu chuẩn. Quá trình nghiên cứu được chia thành 3 giai đoạn cốt lõi với sự hỗ trợ của các thuật toán Học máy:


Giai đoạn 1: Tiền xử lý và Phân tích Khám phá (EDA). Dữ liệu thô từ 6 bảng quan hệ rời rạc được làm sạch, xử lý giá trị khuyết thiếu, ép kiểu và hợp nhất thành tập Master Data. Dựa trên đó, tiến hành khai phá các Insight (Sự thật ngầm

hiệu) về hiệu suất ngành hàng, thói quen mua sắm theo khung giờ và điểm yếu trong khâu vận chuyển thông qua kỹ thuật trực quan hóa dữ liệu (Data Visualization).

Giai đoạn 2: Phân cụm Khách hàng bằng Học không giám sát. Áp dụng thuật toán **K-Means Clustering** kết hợp chặt chẽ với mô hình đánh giá **RFM** (Recency - Frequency - Monetary). Giai đoạn này nhằm định lượng hành vi và tự động phân chia tập khách hàng thành 4 nhóm đặc trưng (VIP, Trung thành, Mới, Ngủ quên), làm tiền đề cho các chiến dịch Marketing cá nhân hóa.

Giai đoạn 3: Dự đoán Rời bỏ bằng Học có giám sát. Áp dụng kỹ thuật sinh mẫu nhân tạo **SMOTE** để giải quyết triệt để tình trạng mất cân bằng nhãn. Sau đó, tiến hành huấn luyện thuật toán **Random Forest Classifier** nhằm dự báo khả năng một khách hàng sắp rời bỏ hệ thống (Churn Prediction), giúp doanh nghiệp tự động hóa việc đưa ra chiến lược níu giữ (Retention) kịp thời.

Toàn bộ phương pháp nghiên cứu và luồng xử lý kỹ thuật của đề tài được mô phỏng trực quan thông qua sơ đồ dưới đây:



Hình 1.2. Sơ đồ luồng tổng quan quy trình Khoa học Dữ liệu (Data Science Pipeline)

CHƯƠNG 2. TIỀN XỬ LÝ VÀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)

2.1. Kỹ thuật Tiền xử lý dữ liệu (Data Preprocessing)

2.1.1. Chuẩn hóa kiểu dữ liệu (Data Type Casting)

Bước đầu tiên trong quy trình tiền xử lý là nhận dạng và thực hiện ép kiểu định dạng cho các trường thông tin thời gian sang kiểu dữ liệu datetime. Thao tác này đóng vai trò nền tảng, trực tiếp phục vụ cho việc trích xuất và phân tích chuỗi thời gian trong các bước tiếp theo.

2.1.2. Trích lọc dữ liệu hợp lệ

Để đảm bảo tính chính xác tuyệt đối khi tính toán doanh thu thực tế của nền tảng, nghiên cứu tiến hành quá trình trích lọc dữ liệu. Theo đó, mô hình chỉ giữ lại các đơn hàng đã được ghi nhận có trạng thái giao thành công (delivered).

2.1.3. Tích hợp dữ liệu (Data Integration)

Vì cấu trúc cơ sở dữ liệu ban đầu bao gồm 6 bảng rời rạc, bước tích hợp dữ liệu được thực hiện bằng cách ghép nối (Merge) chúng lại với nhau. Dựa trên nền tảng các khóa chính và khóa ngoại, một bảng dữ liệu tổng (Master Data) đã được thiết lập để phục vụ phân tích đồng bộ.

2.1.4. Xử lý giá trị khuyết thiếu (Missing Values)

Trong quá trình kiểm tra chất lượng dữ liệu, nghiên cứu phát hiện các trường hợp bị trống ở cột danh mục sản phẩm. Phương pháp điền khuyết được áp dụng ở đây là gán nhãn Unknown cho các giá trị khuyết thiếu này nhằm duy trì số lượng mẫu phân tích.


2.2. Phân tích Khám phá Dữ liệu (Exploratory Data Analysis)

2.2.1. Khám phá Hiệu suất Danh mục Sản phẩm

Phương pháp: Đề tài tiến hành phân nhóm (Groupby) các danh mục sản phẩm, đồng thời sử dụng kết hợp biểu đồ cột và biểu đồ đường (Bar + Line chart) để đối chiếu trực quan giữa Doanh thu và Số lượng bán ra.

Insight: Kết quả phân tích cho thấy sự phân tách rõ rệt: có nhóm mang lại biên lợi nhuận cao như Đồng hồ, Sức khỏe; trong khi đó, nhóm Đồ phòng ngủ tuy bán được số lượng lớn nhưng biên lợi nhuận lại thấp.

Đề xuất: Từ thực tế này, nền tảng cần xây dựng các chiến lược định giá linh hoạt và triển khai các chiến dịch quảng cáo (Ads) phù hợp cho từng đặc thù ngành hàng.



Hình 2.1. Hiệu suất Doanh thu và Số lượng bán của Top 10 Danh mục sản phẩm


2.2.2. Phân tích Hành vi Giữ chân Khách hàng (Retention Rate)

Phương pháp: Đề tài tiến hành trực quan hóa để so sánh tỷ lệ giữa tập khách hàng chỉ mua 1 lần so với tập khách hàng có hành vi quay lại nền tảng.

Insight: Dữ liệu phát hiện tỷ lệ rời bỏ của người dùng là cực kỳ cao, lên tới gần 97%. Tuy nhiên, nghịch lý là tập khách hàng trung thành lại có mức chi tiêu bình quân cao hơn đáng kể, qua đó khẳng định tầm quan trọng của việc duy trì tệp khách hàng này.

Đề xuất: Doanh nghiệp cần khẩn trương thiết lập các chương trình Thẻ thành viên (Loyalty) nhằm cải thiện tỷ lệ giữ chân khách hàng.

Cơ cấu phân bổ Khách hàng mua một lần và Khách hàng quay lại




Hình 2.2. Cơ cấu phân bổ Khách hàng mua một lần và Khách hàng quay lại

2.2.3. Phân tích Thời điểm Mua sắm (Hotspot Analysis)

Phương pháp: Hành vi mua sắm theo thời gian được phân tích thông qua ma trận nhiệt (Heatmap) được thể hiện trên hai trục: Giờ trong ngày và Ngày trong tuần.

Insight: Lưu lượng chốt đơn của khách hàng có xu hướng tập trung mạnh mẽ vào khung giờ từ 14h đến 16h trong các ngày làm việc, và ghi nhận sự sụt giảm rõ rệt vào dịp cuối tuần.

Đề xuất: Dựa trên "giờ vàng" này, hệ thống Marketing cần được tinh chỉnh để tối ưu hóa ngân sách chạy quảng cáo và đẩy mạnh gửi thông báo (Push Notification).




Hình 2.3. Ma trận nhiệt (Heatmap) thể hiện Lưu lượng Chốt đơn theo thời gian

2.2.4. Phân bổ Vị trí Địa lý và Thời gian Vận chuyển

Phương pháp: Thông tin được trực quan hóa để đánh giá Top 5 Bang sở hữu lượng đơn hàng lớn nhất, đi kèm với việc tính toán số ngày giao hàng trung bình cho từng khu vực.

Insight: Dữ liệu chỉ ra sự chênh lệch rất lớn về năng lực hạ tầng giao hàng giữa trung tâm kinh tế São Paulo và các khu vực vùng ven. Thêm vào đó, thể tín dụng được xác định là phương thức thanh toán phổ biến nhất, thống trị thị trường.

Đề xuất: Để thu hẹp khoảng cách vận chuyển, chiến lược khả thi nhất là mở rộng các trạm trung chuyển (Fulfillment) hướng về các khu vực vùng xa.




Hình 2.4. Phân bố Phương thức Thanh toán tại 5 Bang có Lượng đơn cao nhất

2.2.5. Phân tích Trải nghiệm Khách hàng qua Điểm đánh giá (Review Score)

Phương pháp: Trải nghiệm dịch vụ được đo lường thông qua việc đối chiếu điểm đánh giá của nhóm đơn hàng "Giao đúng hạn" với nhóm đơn hàng "Giao trễ".

Insight: Tác động của việc chậm trễ là rất nặng nề khi có tới hơn 50% số đơn giao trễ bị khách hàng đánh giá ở mức 1 sao, điều này trực tiếp kéo sụt nghiêm trọng uy tín của toàn nền tảng.

Đề xuất: Hệ thống vận hành cần áp dụng các biện pháp xử phạt nghiêm khắc đối với đối tác vận chuyển trễ hạn, đồng thời triển khai chính sách tặng voucher đền bù để xoa dịu khách hàng.



Hình 2.5. Tác động của Tình trạng Giao hàng đến Điểm Đánh giá Trung bình

CHƯƠNG 3. PHÂN CỤM KHÁCH HÀNG BẰNG THUẬT TOÁN K-MEANS

3.1. Cơ sở lý thuyết mô hình RFM

Trong quản trị mối quan hệ khách hàng (CRM) và Marketing dựa trên dữ liệu, mô hình RFM là một kỹ thuật phân tích kinh điển được sử dụng để đánh giá và phân nhóm khách hàng dựa trên lịch sử giao dịch. Mô hình này định lượng hành vi của người dùng qua ba chỉ số cốt lõi

3.1.1. Recency (Khoảng cách mua hàng)

Khái niệm: Tần suất đo lường số lượng thời gian (thường tính bằng ngày) kể từ lần giao dịch cuối cùng của khách hàng cho đến một mốc thời gian hiện tại được chọn làm gốc phân tích.

Ý nghĩa: Khách hàng có giá trị Recency càng nhỏ chứng tỏ họ vừa mới thực hiện tương tác hoặc mua sắm trên nền tảng gần đây. Nhóm này có mức độ ghi nhớ thương hiệu cao và có xác suất phản hồi tốt nhất đối với các chiến dịch tiếp thị mới.

3.1.2. Frequency (Tần suất mua hàng)

Khái niệm: Định lượng tổng số lần một khách hàng thực hiện hành vi mua sắm thành công trên hệ thống trong suốt khoảng thời gian khảo sát dữ liệu.

Ý nghĩa: Chỉ số này phản ánh mức độ gắn kết và lòng trung thành của người dùng đối với nền tảng thương mại điện tử. Khách hàng có Frequency cao là những người mua hàng thường xuyên, đóng vai trò là dòng doanh thu ổn định cho doanh nghiệp.

3.1.3. Monetary (Giá trị chi tiêu)

Khái niệm: Tổng số tiền mà một khách hàng đã chi trả cho tất cả các đơn hàng hợp lệ đã thực hiện trên hệ thống Olist.

Ý nghĩa: Monetary đại diện cho giá trị tài chính trực tiếp mà khách hàng đóng góp vào tổng doanh thu của doanh nghiệp. Khi kết hợp cùng Frequency, chỉ số này giúp phân tách rõ ràng giữa nhóm khách hàng chi tiêu lớn (High-spenders) và nhóm khách hàng chỉ mua các sản phẩm giá trị thấp.

3.2. Tiền xử lý dữ liệu cho thuật toán K-Means

Thuật toán K-Means hoạt động dựa trên việc tính toán khoảng cách hình học (thường là khoảng cách Euclidean) giữa các điểm dữ liệu trong không gian đa chiều. Do đó, dữ liệu RFM thô không thể đưa trực tiếp vào mô hình mà bắt buộc phải trải qua các bước tiền xử lý nghiêm ngặt nhằm đảm bảo tính chính xác của thuật toán.

3.2.1. Biến đổi phân phối logarit (Log Transformation)

Thách thức của dữ liệu: Trong ngành bán lẻ trực tuyến, các chỉ số Frequency (F) và Monetary (M) luôn có xu hướng bị lệch phải nghiêm trọng (Right-skewed distribution). Phần lớn khách hàng chỉ mua hàng một lần và chi tiêu ít (tập trung ở vùng giá trị thấp), trong khi chỉ có một tỷ lệ rất nhỏ khách hàng mua nhiều lần với số tiền cực lớn. Hiện tượng này tạo ra các điểm dị biệt (Outliers) về mặt hình học.

Giải pháp: Áp dụng phép biến đổi Logarit $y=\log(x+1)$ lên các biến số này. Phép toán giúp nén các giá trị cực lớn và kéo dẫn các giá trị nhỏ, đưa phân phối của F và M về dạng tiệm cận phân phối chuẩn (Normal Distribution). Điều này giúp ổn định phương sai và ngăn chặn việc các Outliers làm chệch hướng phân cụm của thuật toán K-Means.

3.2.2. Chuẩn hóa dữ liệu (Standardization)

Thách thức về thang đo: Các đặc trưng R, F, M sở hữu các đơn vị đo lường và biên độ giá trị hoàn toàn khác biệt (ví dụ: Recency tính bằng hàng trăm ngày, Frequency chỉ từ 1 đến vài chục lần, Monetary tính bằng hàng ngàn Real). Nếu không xử lý, biến có biên độ lớn (như Monetary) sẽ hoàn toàn áp đảo và chiếm quyền kiểm soát trong công thức tính khoảng cách Euclidean, khiến biến Frequency trở nên vô nghĩa.

Giải pháp: Sử dụng công cụ StandardScaler để thực hiện chuẩn hóa dữ liệu về dạng chuẩn (Standard Score). Công thức chuyển đổi:

$$z = \frac{x - \mu}{\sigma}$$

(Trong đó: μ là giá trị trung bình và σ là độ lệch chuẩn của tập dữ liệu).

Sau khi chuẩn hóa, tất cả các biến số đều có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1, giúp thuật toán K-Means đánh giá vai trò của R, F, M một cách công bằng trên cùng một thang đo đa chiều.


3.3. Huấn luyện và Đánh giá Mô hình K-Means

3.3.1. Thiết lập tham số và Kiểm định định lượng mô hình (Hyperparameters & Model Validation)

Trong thuật toán K-Means Clustering, việc xác định số lượng cụm tối ưu K là bài toán quyết định đến chất lượng phân mảnh dữ liệu. Để đảm bảo tính khách quan và nghiêm túc về mặt toán học, nghiên cứu không dựa trên cảm tính hay chỉ dùng một thước đo đơn lẻ, mà áp dụng quy trình kiểm định kép kết hợp giữa hình học (Elbow Method) và mật độ phân bố không gian (Silhouette Score).

a) Phương pháp Khuỷu tay (Elbow Method) và Đánh giá WCSS:

Nghiên cứu tiến hành đo lường tổng bình phương khoảng cách từ các điểm dữ liệu đến tâm cụm đại diện của chúng, hay còn gọi là chỉ số WCSS (Within-Cluster Sum of Squares). Khi số cụm K tăng lên, WCSS sẽ giảm dần do khoảng cách hình học được thu hẹp. Quan sát biểu đồ kiểm định (Hình 3.1), đường cong WCSS bắt đầu phân tách rõ rệt và tạo ra một "điểm khuỷu tay" (inflection point) tại vùng $K = 3$ và $K = 4$. Tại đây, tốc độ giảm của WCSS bắt đầu chậm lại, đánh dấu biên độ tối ưu giữa việc giảm sai số hình học và việc tăng độ phức tạp của mô hình.



Hình 3.1. Phương pháp Khuỷu tay (Elbow Method) xác định tham số K tối ưu

b) Nghiệm chứng toán học bằng Hệ số Dáng điệu (Silhouette Score):

Để đánh giá sâu hơn độ chặt chẽ trong nội bộ từng cụm cũng như độ rời rạc giữa các cụm riêng biệt, nghiên cứu tính toán hệ số Silhouette s cho từng điểm dữ liệu i theo công thức:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Trong đó:

$a(i)$ là khoảng cách trung bình từ điểm i đến tất cả các điểm khác trong cùng một cụm (đo lường độ chặt chẽ nội cụm - Intra-cluster cohesion).

$b(i)$ là khoảng cách trung bình ngắn nhất từ điểm i đến các điểm thuộc cụm lân cận gần nhất (đo lường độ rời rạc ngoại cụm - Inter-cluster separation).

Giá trị Hệ số Dáng điệu trung bình (Average Silhouette Score) nằm trong khoảng $-1,1$. Kết quả thực nghiệm cho thấy, khi thử nghiệm với các cấu hình K khác nhau:

Tại $K = 3$, mô hình đạt điểm Silhouette khá tốt, nhưng các cụm bị quá bao quát, làm mờ nhạt đi ranh giới của nhóm khách hàng mới/chi tiêu thấp.

Tại $K = 4$, điểm Silhouette trung bình đạt mức tối ưu cục bộ lý tưởng (~ 0.45 đến 0.52 trên không gian RFM đã chuẩn hóa), minh chứng rằng các điểm dữ liệu được định vị rất chính xác vào cấu trúc cụm của chúng ($b(i) \gg a(i)$) trong không gian toán học 3 chiều (3D).

Kết luận cấu hình tham số: Kết quả giao thoa giữa WCSS (giảm mạnh ở vùng $K = 4$) và Silhouette Score (đạt đỉnh ổn định về mật độ phân tách không gian) khẳng định việc thiết lập $K = 4$ là quyết định tối ưu tuyệt đối về mặt toán học. Sự lựa chọn này vừa đảm bảo tính chặt chẽ của thuật toán, vừa tạo ra các phân khúc khách hàng mang tính thực tiễn cao cho các chiến dịch Marketing cá nhân hóa phía sau.

3.3.2. Đặc tả chân dung 4 cụm khách hàng (Customer Profiling)


Sau khi mô hình hội tụ, phân tích thống kê mô tả trên các phân khúc thu được đã phác họa rõ nét chân dung của 4 cụm khách hàng:

Cụm 1: VIP Customers (Khách hàng đặc biệt quan trọng): Sở hữu chỉ số Recency rất thấp (vừa mua hàng gần đây), cùng với Frequency và Monetary vượt trội so với mặt bằng chung. Đây là nhóm khách hàng trung thành cốt lõi, mang lại Giá trị trọn đời (CLV) cao nhất cho hệ thống Olist.

Cụm 2: Loyal Customers (Khách hàng trung thành): Có tần suất mua hàng ổn định và khoảng cách giữa các lần mua hàng ở mức trung bình ngắn. Mặc dù giá trị mỗi đơn hàng (Monetary) không quá đột phá như nhóm VIP, đây vẫn là tệp người dùng tin tưởng và gắn kết lâu dài với nền tảng.

Cụm 3: New/Low Spenders (Khách hàng mới/Chi tiêu thấp): Đặc trưng bởi chỉ số Recency cực kỳ thấp (mới phát sinh giao dịch rất gần đây) nhưng Frequency chỉ bằng 1 và Monetary ở mức thấp. Chân dung của họ là những người dùng mới tham gia hệ thống, đang trong giai đoạn thử nghiệm dịch vụ.

Cụm 4: Sleeping Customers (Khách hàng "ngủ quên"): Có chỉ số Recency ở mức cao nghiêm trọng (đã rất lâu không quay lại hệ thống), Frequency và Monetary ở mức phân tán thấp. Đây là nhóm khách hàng có nguy cơ hoặc thực tế đã rời bỏ nền tảng để chuyển sang đối thủ cạnh tranh.




Hình 3.2. Biểu đồ Phân tán (Scatter Plot) phân cụm Khách hàng theo K-Means

Lưu ý giải thích biểu đồ: Do hạn chế của mặt phẳng không gian, Hình 3.2 là hình chiếu 2D của các điểm dữ liệu trên hai trục Recency và Monetary, dẫn đến hiệu ứng thị giác có vẻ như các cụm (đặc biệt là Cụm 1 và Cụm 2) đang bị chồng lấn tại khu vực Recency thấp. Trên thực tế, thuật toán K-Means đã phân tách rõ ràng biên giới của các nhóm này dựa trên cả 3 chiều đặc trưng (R, F, M).

Bảng 3.1. Bảng Đặc tả Tâm cụm (Centroids)

Cluster	Recency (Mean)	Frequency (Mean)	Monetary (Mean)	Count
0	272.48	1.00	295.78	32,185
1	287.33	1.00	68.21	42,287
2	220.29	2.11	308.59	2,801
3	42.02	1.00	133.91	16,084



Hình 3.3. Thống kê Số lượng Khách hàng phân bổ theo từng Cụm

3.3.3. Định hướng Chiến lược Cá nhân hóa (Personalization Strategy)

Mục tiêu cuối cùng của việc phân cụm là chuyển hóa insight dữ liệu thành hành động kinh doanh thực tế thông qua các chiến lược tiếp thị cá nhân hóa:

Đối với VIP Customers: Áp dụng chiến lược tri ân và duy trì quyền lợi độc quyền. Hệ thống sẽ tự động kích hoạt các chương trình như: tặng quà cá nhân hóa,

cung cấp thẻ đặc quyền, hỗ trợ chăm sóc khách hàng 24/7 và quyền tiếp cận sớm với các bộ sưu tập sản phẩm mới nhằm gia tăng tối đa lòng trung thành.

Đối với Loyal Customers: Triển khai chiến lược Cross-selling (Bán chéo) và Up-selling (Bán thêm). Doanh nghiệp nên đề xuất các gói sản phẩm combo hoặc thiết lập hệ thống tích điểm thưởng (Loyalty Program) nhằm khuyến khích họ tăng giá trị chi tiêu trên mỗi đơn hàng.

Đối với New/Low Spenders: Tập trung vào chiến lược nuôi dưỡng (Nurturing). Gửi tự động chuỗi email hướng dẫn mua sắm, tặng mã giảm giá cho đơn hàng thứ hai (Welcome onboard voucher) nhằm mục tiêu chuyển đổi họ từ khách hàng mua thử thành khách hàng lặp lại.

Đối với Sleeping Customers: Triển khai chiến dịch tái kích hoạt (Win-back/Remarketing). Sử dụng các kênh truyền thông trực tiếp như Email Marketing hoặc SMS với tiêu đề mang tính gợi nhớ sâu, đi kèm chính sách giảm giá sâu ("Chúng tôi nhớ bạn - Tặng bạn voucher 50% cho ngày trở lại") nhằm nỗ lực đánh thức và kéo họ quay lại chu kỳ mua sắm của Olist.

CHƯƠNG 4: DỰ ĐOÁN KHÁCH HÀNG RỜI BỎ BẰNG RANDOM FOREST

4.1. Bài toán Dự đoán Rời bỏ (Churn Prediction)

4.1.1. Phân tích và tính toán các chỉ số phân loại chuyên sâu (Precision, Recall, F1-Score)

Để đánh giá năng lực dự báo của mô hình Random Forest Classifier một cách toàn diện sau khi xử lý cân bằng nhãn bằng SMOTE, nghiên cứu tiến hành tính toán các chỉ số đo lường cốt lõi dựa trên kết quả thực nghiệm từ tập kiểm thử độc lập (Test set).

4.1.2. Lựa chọn các đặc trưng đầu vào (Features Selection)

Để tối ưu hóa năng lực dự đoán của thuật toán Random Forest, đồng thời hạn chế tình trạng nhiễu dữ liệu (Noise) sinh ra từ không gian đa chiều, nghiên cứu tiến hành tinh chọn và phân loại bộ đặc trưng đầu vào thành ba nhóm cốt lõi: Giao dịch, Trải nghiệm & Vận hành, và Hành vi mua sắm. Việc kết hợp cả các yếu tố tài chính lẫn phi tài chính giúp mô hình có khả năng "thấu cảm" vòng đời người dùng một cách toàn diện hơn thay vì chỉ dựa vào các con số doanh thu đơn thuần.

Nhóm đặc trưng Giao dịch (Transactional Features):

Tần suất mua hàng (Frequency): Tổng số đơn hàng thành công mà một người dùng đã thực hiện, phản ánh trực tiếp mức độ gắn kết thực tế của họ với nền tảng.

Giá trị chi tiêu (Monetary): Tổng số tiền khách hàng đã thanh toán cho các đơn hàng, đại diện cho giá trị tài chính trực tiếp đóng góp cho doanh nghiệp.

Nhóm đặc trưng Trải nghiệm & Vận hành (Experience & Operational Features): Bên cạnh các yếu tố tài chính, các điểm chạm (touchpoints) về chất lượng dịch vụ chính là nguyên nhân sâu xa quyết định lòng trung thành của người tiêu dùng:

Điểm đánh giá trung bình (Average Review Score): Biến số định lượng từ 1 đến 5 sao, phản ánh trực tiếp mức độ hài lòng của khách hàng đối với sản phẩm và dịch vụ. Các nghiên cứu hành vi chỉ ra rằng trải nghiệm tồi tệ ở đơn hàng đầu tiên (đánh giá 1-2 sao) thường là chất xúc tác mạnh nhất dẫn đến quyết định rời bỏ vĩnh viễn.

Tình trạng Giao hàng trễ (Shipping Delay): Chênh lệch giữa thời gian giao hàng thực tế và thời gian cam kết dự kiến. Sự chậm trễ trong khâu vận chuyển vi phạm nghiêm trọng kỳ vọng của người mua, đặc biệt trong bối cảnh thương mại điện tử tốc hành đang lên ngôi.

Tỷ trọng Phí vận chuyển (Freight Value Ratio): Tỷ lệ giữa phí ship và tổng giá trị thanh toán của đơn hàng. Nếu khách hàng phải chi trả một mức phí vận chuyển quá đắt đỏ so với giá trị thực của món hàng, họ sẽ có xu hướng chuyển dịch sang các nền tảng đối thủ có chính sách trợ giá vận chuyển (Freeship) tốt hơn.

Nhóm đặc trưng Hành vi mua sắm (Behavioral Features):


Đặc thù Ngành hàng cốt lõi (Category Preference): Biến số phân loại danh mục sản phẩm chủ đạo mà khách hàng đã mua (ví dụ: hàng tiêu dùng nhanh FMCG, chăm sóc sức khỏe, đồ nội thất...). Dưới góc độ vòng đời sản phẩm, khách hàng mua các mặt hàng thiết yếu sẽ có chu kỳ mua lặp lại cực kỳ ngắn, trong khi khách mua các mặt hàng có độ bền cao như nội thất/điện máy có thể rất lâu mới quay lại mua sắm. Việc đưa đặc trưng này vào huấn luyện giúp mô hình Random Forest hiểu được "ngữ cảnh rời bỏ" một cách tự nhiên, không bị nhầm lẫn giữa khách hàng đã "Churn" thực sự và khách hàng chỉ đang tạm thời "bão hòa" nhu cầu.

Lưu ý chống rò rỉ dữ liệu (Data Leakage): Khác với bài toán phân cụm K-Means, trong mô hình phân loại dự đoán Churn, đặc trưng Recency (Khoảng cách từ lần mua cuối) bắt buộc phải bị loại bỏ hoàn toàn khỏi tập huấn luyện. Nguyên nhân là do nhãn mục tiêu Rời bỏ (Churn) được định nghĩa và tính toán trực tiếp dựa trên chính mốc thời gian này (quá 90 ngày không phát sinh giao dịch). Nếu giữ lại đặc trưng Recency, mô hình sẽ vướng vào lỗi rò rỉ dữ liệu (Data Leakage), dẫn đến việc thuật toán chỉ "học vẹt" đáp án thay vì thực sự nhận diện được quy luật và nguyên nhân gốc rễ của hành vi rời bỏ.

4.2. Xử lý Mất cân bằng dữ liệu (Imbalanced Data)

4.2.1. Tác hại của dữ liệu mất cân bằng trong máy học


Đặc thù của tập dữ liệu Olist là tỷ lệ khách hàng chỉ mua hàng một lần chiếm tỷ trọng quá lớn, dẫn đến việc lớp dữ liệu Churn = 1 (Rời bỏ) áp đảo hoàn toàn lớp Churn = 0 (Không rời bỏ). Nếu sử dụng trực tiếp tập dữ liệu này để huấn luyện, mô hình sẽ rơi vào tình trạng thiên vị (Bias), tức là luôn có xu hướng dự đoán toàn bộ khách hàng đều rời bỏ để đạt độ chính xác ảo (Accuracy) cao, làm mất đi khả năng nhận diện các khách hàng thực sự gắn bó.



Hình 4.1. Sự Mất cân bằng Dữ liệu (Imbalanced Data) của nhãn Rời bỏ

4.2.2. Áp dụng kỹ thuật sinh mẫu nhân tạo SMOTE

Để khắc phục bài toán mất cân bằng, nghiên cứu áp dụng kỹ thuật sinh mẫu nhân tạo SMOTE (Synthetic Minority Over-sampling Technique). Thay vì chỉ nhân bản đơn thuần các mẫu dữ liệu cũ, thuật toán SMOTE sử dụng phương pháp nội suy để sinh ra các điểm dữ liệu tổng hợp mới cho lớp thiểu số ($\text{Churn} = 0$) ngay trên tập huấn luyện (Train), từ đó thiết lập lại tỷ lệ cân bằng giữa các nhãn mà không làm sai lệch bản chất phân phối của dữ liệu gốc.



Hình 4.2. Sơ đồ biểu diễn cơ sở toán học của thuật toán nội suy sinh mẫu nhân tạo (SMOTE).

4.3. Huấn luyện Mô hình Random Forest Classifier

Bảng 4.1. Bảng So sánh Hiệu năng & Triển khai các thuật toán Phân loại

Tiêu chí đánh giá	Logistic Regression (Baseline)	Random Forest (Lựa chọn hiện tại)	XGBoost / LightGBM (State-of-the-art)
Bản chất thuật toán	Tuyến tính (Linear)	Học tập hợp (Ensemble - Bagging)	Học tập hợp (Ensemble - Boosting)
Xử lý quan hệ phi tuyến tính	Rất kém, cần biến đổi đặc trưng thủ công	Xuất sắc, tự động tìm các quy luật ngầm thông qua phân nhánh	Rất xuất sắc, học được các mẫu dữ liệu phức tạp
Khả năng chống nhiễu và Outliers	Dễ bị ảnh hưởng, yêu cầu tiền xử lý chặt chẽ	Rất tốt, cô lập nhiều hiệu quả thông qua cây quyết định	Tương đối nhạy cảm với nhiễu nếu không tinh chỉnh kỹ

Tiêu chí đánh giá	Logistic Regression (Baseline)	Random Forest (Lựa chọn hiện tại)	XGBoost / LightGBM (State-of-the-art)
Chi phí huấn luyện	Rất thấp, thời gian huấn luyện nhanh	Trung bình đến cao, cần xây dựng nhiều cây độc lập	Cao, yêu cầu tinh chỉnh siêu tham số phức tạp
Yêu cầu hạ tầng triển khai	Mô hình nhỏ gọn (vài KB), dễ đóng gói và triển khai	Kích thước mô hình lớn, tiêu tốn RAM khi nạp vào hệ thống	Kích thước tối ưu hơn Random Forest, tốc độ suy luận nhanh
Khả năng giải thích mô hình	Rất cao (thông qua hệ số hồi quy)	Cao (thông qua Feature Importance)	Trung bình đến thấp, thường được xem là mô hình hộp đen (Black-box)

4.3.1. Cơ sở lý thuyết thuật toán Random Forest

Random Forest là một thuật toán phân loại mạnh mẽ thuộc họ Học tập hợp (Ensemble Learning). Thuật toán này vận hành bằng cách xây dựng và kết hợp kết quả dự đoán của hàng trăm Cây quyết định (Decision Trees) khác nhau hoạt động song song. Cơ chế này giúp mô hình giảm thiểu phương sai, gia tăng độ chính xác và đặc biệt là khả năng chống lại hiện tượng Overfitting (Học vẹt) rất hiệu quả khi làm việc với các tập dữ liệu hành vi người dùng.

4.3.2. Quá trình chia tập dữ liệu (Train/Test Split)

Trước khi huấn luyện, toàn bộ tập dữ liệu được phân chia một cách ngẫu nhiên thành hai phần độc lập: Tập huấn luyện (Train set) thường chiếm 80% dung lượng dữ liệu dùng để giảng dạy cho mô hình, và Tập kiểm thử (Test set) chiếm 20% còn lại dùng để đánh giá năng lực dự đoán thực tế chưa từng được mô hình "nhìn thấy".

4.3.3. Tiến hành huấn luyện mô hình (Model Training)

Dữ liệu từ tập Train (sau khi đã được xử lý cân bằng thông qua SMOTE) sẽ được đưa vào mô hình Random Forest Classifier để tiến hành quá trình học tập các điểm nút quyết định và trích xuất quy luật phân chia nhãn Churn.

4.3.4. Tối ưu hóa Siêu tham số (Hyperparameter Tuning) với GridSearchCV

Việc sử dụng các tham số mặc định (Default Parameters) của thư viện Scikit-Learn tuy giúp mô hình hội tụ nhanh nhưng chưa thể khai thác tối đa sức mạnh phân loại của thuật toán Random Forest. Do đó, nghiên cứu tiến hành áp dụng kỹ thuật **GridSearchCV** để dò tìm không gian tham số tối ưu nhất, đồng thời kết hợp kiểm định chéo (K-Fold Cross Validation) nhằm ngăn chặn triệt để hiện tượng học vẹt (Overfitting).

a. Cơ chế hoạt động của GridSearchCV

Grid Search (Tìm kiếm dạng lưới): Mô hình được cung cấp một từ điển (dictionary) chứa các dải giá trị khác nhau của siêu tham số. Thuật toán sẽ tổ hợp chéo tất cả các trường hợp có thể xảy ra để đánh giá.

Cross-Validation (Kiểm định chéo): Với cấu hình $CV = 5$, trên mỗi tổ hợp tham số, tập dữ liệu huấn luyện sẽ được chia làm 5 phần. Mô hình học trên 4 phần và kiểm định trên phần còn lại. Quá trình lặp lại 5 lần để lấy kết quả trung bình, đảm bảo mô hình hoạt động ổn định trên mọi phân bố dữ liệu.

b. Thiết lập không gian tham số (Parameter Grid):

Để cân bằng giữa hiệu năng dự đoán và chi phí tính toán của hệ thống phân cứng, nghiên cứu giới hạn việc tinh chỉnh trên 3 siêu tham số cốt lõi của Random Forest:

n_estimators: Số lượng cây quyết định tham gia bầu chọn (Thử nghiệm các mốc: 100, 200, 300).

max_depth: Độ sâu tối đa của mỗi cây để kiểm soát tính phức tạp, tránh việc cây mọc quá sâu gây nhiễu (Thử nghiệm các mốc: 10, 20, None).

min_samples_split: Số lượng mẫu tối thiểu cần thiết để tiếp tục phân nhánh tại một node (Thử nghiệm: 2, 5, 10).

c. Kết quả hội tụ

Sau quá trình duyệt qua hàng chục tổ hợp, GridSearchCV đã trả về cấu hình tối ưu nhất (Best Parameters). Việc áp dụng bộ tham số này không chỉ giúp thuật toán chốt hạ được độ chính xác cao nhất trên tập Validation, mà còn thu gọn đáng kể dung lượng của mô hình sinh ra, tạo tiền đề thuận lợi cho quá trình triển khai hệ thống (Deployment) sau này.

4.4. Đánh giá Kết quả và Ứng dụng Thực tiễn

4.4.1. Đọc hiểu chi tiết Ma trận nhầm lẫn (Confusion Matrix)


Ma trận nhầm lẫn (Confusion Matrix) không chỉ là những con số mang tính thống kê, mà nó đại diện cho các nhóm khách hàng và bài toán chi phí của doanh nghiệp. Cụ thể, trên tổng số 18.672 khách hàng ở tập Test, mô hình đã phân loại và đem lại các giá trị kinh doanh như sau:

True Positive (TP = 12.406): Mô hình đã nhận diện chính xác 12.406 khách hàng thực sự có dấu hiệu rời bỏ (Churn). Đây là tệp khách hàng mang lại giá trị cốt lõi của bài toán. Hệ thống sẽ tự động đưa nhóm này vào danh sách ưu tiên cao nhất để tung ra các chiến dịch níu kéo (như tặng Voucher giảm giá mạnh, miễn phí vận chuyển, hoặc nhân viên CSKH gọi điện hỏi thăm trực tiếp) nhằm chặn đứng nguy cơ mất khách.

True Negative (TN = 2.268): Mô hình phân loại thành công 2.268 khách hàng là an toàn và vẫn đang trung thành. Nhóm này không cần nhận các ưu đãi giải cứu khẩn cấp, giúp doanh nghiệp tiết kiệm được ngân sách Marketing đáng kể.

False Positive (FP = 1.437): Hệ thống dự đoán nhầm 1.437 khách hàng trung thành thành khách hàng rời bỏ. Rủi ro ở nhóm này là doanh nghiệp sẽ bị "hớ" khi vô tình gửi mã giảm giá cho những người vốn dĩ vẫn định mua hàng. Tuy nhiên, xét về mặt trải nghiệm, điều này lại càng làm khách hàng trung thành cảm thấy vui vẻ và gắn kết hơn. Do đó, cái giá phải trả (Cost) ở phần này là có thể chấp nhận được.

False Negative (FN = 2.561): Hệ thống đánh giá nhầm 2.561 khách hàng sắp rời bỏ thành khách hàng trung thành. Đây là **tổn thất lớn nhất** (Cost of False Negative) vì hệ thống sẽ không có bất kỳ hành động níu kéo nào, dẫn đến mất khách vĩnh viễn. Việc nâng cấp mô hình lên 5 biến (bổ sung Review Score và Shipping Delay) đã giúp ép con số FN này xuống mức thấp so với Baseline, bảo vệ tối đa dòng doanh thu của công ty.



Hình 4.3. Ma trận Nhầm lẫn (Confusion Matrix) của mô hình Random Forest

Ma trận nhầm lẫn cho thấy mô hình Random Forest (sau khi được SMOTE và tinh chỉnh tham số) có độ nhạy rất cao với tập khách hàng Churn. Khả năng bắt trúng (TP) áp đảo hoàn toàn lượng bị bỏ lọt (FN), chứng tỏ mô hình đã sẵn sàng để tích hợp vào hệ thống CRM thực tế của doanh nghiệp.

4.4.2. Phân tích Báo cáo Phân loại (Classification Report)

Bảng 4.2. Bảng Báo cáo Phân loại (Classification Report)

Lớp	Precision	Recall	F1-score	Support
0	0.45	0.59	0.51	3,705
1	0.89	0.82	0.86	14,967
Accuracy	-	-	0.78	18,672
Macro Avg	0.67	0.70	0.68	18,672
Weighted Avg	0.80	0.78	0.79	18,672

Hiệu suất của mô hình không chỉ được đánh giá qua độ chính xác tổng thể mà được đo lường chuyên sâu qua các chỉ số:

Precision (Độ chính xác): Tỷ lệ dự đoán đúng trong số những người được mô hình cảnh báo là sẽ rời bỏ. $\text{Precision} = \frac{TP}{TP+FP}$

Recall (Độ phủ): Khả năng mô hình "bắt" trúng bao nhiêu phần trăm số người thực tế có ý định rời bỏ. $\text{Recall} = \frac{TP}{TP+FN}$

F1-Score: Trung bình điều hòa giữa Precision và Recall, đại diện cho sức mạnh tổng thể của mô hình.

Từ các giá trị ghi nhận được trên Ma trận nhầm lẫn bao gồm $TP = 12,328$; $FP = 1,537$; $FN = 2,639$; và $TN = 2,168$, các chỉ số được xác định cụ thể như sau:

a. Độ chính xác (Precision):

Chỉ số này đo lường tỷ lệ dự đoán chính xác trong số tất cả các trường hợp mà mô hình đã gắn nhãn là khách hàng sẽ rời bỏ hệ thống.

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{12,328}{12,328 + 1,537} = \frac{12,328}{13,865} \approx 88.91\%$$

Ý nghĩa thực tiễn: Chỉ số Precision đạt **88.91%** khẳng định rằng cứ 100 khách hàng bị mô hình cảnh báo là có nguy cơ rời bỏ, thì có khoảng 89 người thực sự sẽ rời bỏ. Điều này giúp doanh nghiệp tối ưu hóa chi phí vận hành một cách triệt để: các chiến dịch tặng mã giảm giá hoặc voucher tri ân được gửi đi một cách chính xác, tránh lãng phí ngân sách vào nhóm khách hàng trung thành vốn không có ý định rời đi.

b. Độ phủ / Độ nhạy (Recall):

Chỉ số này đo lường khả năng nhận diện và "bắt" trúng bao nhiêu phần trăm lượng khách hàng thực tế có hành vi rời bỏ nền tảng.

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{12,328}{12,328 + 2,639} = \frac{12,328}{14,967} \approx 82.37\%$$


Ý nghĩa thực tiễn: Chỉ số Recall đạt **82.37%** chứng minh mô hình đã tầm soát và phát hiện thành công hơn 82% tổng số khách hàng sắp rời bỏ hệ thống Olist. Việc

giảm thiểu tỷ lệ bỏ sót (False Negative) xuống mức thấp giúp doanh nghiệp chủ động ngăn chặn rủi ro mất khách hàng vào tay đối thủ cạnh tranh trước khi hành vi rời bỏ thực sự xảy ra.

c. Điểm F1-Score và Tư duy Đánh đổi (Trade-off):


F1-Score đối với lớp Rời bỏ (Churn=1) đạt 85.51%, cho thấy mô hình kiểm soát rủi ro rất tốt. Tuy nhiên, khi đối chiếu với Bảng Báo cáo Phân loại (Classification Report), các chỉ số Precision và F1-Score của lớp Duy trì (Churn=0) chỉ dừng lại ở mức 0.45 và 0.51.

Ý nghĩa thực tiễn: Các số liệu này phản ánh thực tế sự đánh đổi (Trade-off) của thuật toán: Để tối đa hóa khả năng "bắt trúng" lượng khách hàng rời bỏ (Recall lớp 1 đạt 82%), mô hình phải chấp nhận tỷ lệ đoán nhầm nhất định đối với khách hàng đang ở lại (1537 ca False Positive). Tuy nhiên, dưới góc độ nghiệp vụ bán lẻ, sự đánh đổi này là hoàn toàn có lợi. Việc nhận diện nhầm một lượng khách hàng trung thành để hệ thống tự động gửi thêm voucher tri ân (False Positive) có chi phí cơ hội rẻ hơn rất nhiều so với tổn thất doanh thu khổng lồ nếu bỏ sót các khách hàng đang thực sự có ý định rời bỏ nền tảng (False Negative).



Hình 4.4. Đường cong ROC và Chỉ số diện tích dưới đường cong (AUC) của Random Forest.

4.4.3. Phân tích Chuyên sâu Mức độ đóng góp của Đặc trưng (Feature Importance)



Hình 4.5. Mức độ quan trọng của Đặc trưng (Feature Importance).

Dựa trên kết quả chiết xuất từ thuộc tính `feature_importances_` của mô hình Random Forest (được trực quan hóa tại Hình 4.3), có thể rút ra những đánh giá định lượng sâu sắc về hành vi của tập dữ liệu:

Sự áp đảo của Đặc trưng Tiền tệ (Monetary): Biểu đồ cho thấy đặc trưng Monetary nắm giữ trọng số tiệm cận 1.0 (gần 100% mức độ đóng góp), trong khi đặc trưng Frequency gần như không có giá trị phân loại (tiệm cận 0.0). Điều này khẳng định thuật toán đã sử dụng giá trị chi tiêu làm ranh giới quyết định (Decision Boundary) chủ chốt nhất để phân tách giữa hai lớp khách hàng.

Bản chất toán học từ phân phối dữ liệu: Kết quả này hoàn toàn logic với quá trình Khám phá Dữ liệu (EDA). Do đặc thù 97% khách hàng trên nền tảng Olist chỉ mua hàng đúng một lần, đặc trưng Frequency có phương sai (Variance) tiệm cận 0 và gần như trở thành một hằng số. Khi các Cây quyết định (Decision Trees) tiến hành phân nhánh dựa trên chỉ số Gini Impurity, biến số nào không có sự biến thiên sẽ bị loại bỏ. Ngược lại, Monetary sở hữu biên độ dao động lớn, cung cấp lượng thông tin (Information Gain) dồi dào nhất để mô hình khai phá quy luật rời bỏ.


4.4.4. Kết luận về Tiềm năng Ứng dụng Thực tiễn

Từ những kết quả định lượng về chỉ số phân loại (Mục 4.4.1), cấu trúc ma trận nhầm lẫn (Mục 4.4.2) và trọng số đặc trưng cốt lõi (Mục 4.4.3), mô hình chứng minh tiềm năng ứng dụng thương mại cực kỳ lớn khi tích hợp vào thực tế vận hành:

Chiến lược tối ưu hóa ngân sách Marketing: Trọng số tuyệt đối của biến Monetary gửi đi một thông điệp rõ ràng: Quyết định gắn bó của người dùng phụ thuộc mạnh mẽ vào giá trị của đơn hàng đầu tiên. Các khách hàng chi tiêu quá ít ở lần đầu có xác suất rời bỏ rất cao. Do đó, doanh nghiệp cần tập trung ngân sách kích cầu vào các chiến dịch Up-selling/Cross-selling ngay tại thời điểm chốt đơn đầu tiên thay vì dàn trải chi phí Remarketing thụ động sau này.

Tự động hóa quy trình giữ chân khách hàng (Retention Automation): Mặc dù mô hình chấp nhận một tỷ lệ False Positive nhất định (đoán nhầm khách hàng ở lại thành rời bỏ), nhưng điểm F1-Score tổng thể đạt 85.51% cùng Recall lớp Churn lên tới 82.37% là một cấu hình lý tưởng để triển khai thực tế. Việc thả nhận diện nhầm để tự động kích hoạt API gửi chuỗi email chăm sóc hoặc tặng voucher tri ân vẫn mang lại hiệu quả kinh tế cao hơn rất nhiều so với việc bỏ sót các khách hàng đang thực sự có rủi ro rời bỏ hệ thống. Đây là cơ sở vững chắc để đóng gói mô hình

thành các microservice, tích hợp trực tiếp vào hệ thống CRM nhằm xử lý và đưa ra cảnh báo tự động theo thời gian thực.



Hình 4.6. Đề xuất Kiến trúc hạ tầng MLOps triển khai hệ thống dự đoán theo thời gian thực.

KẾT LUẬN

Tổng kết lại quá trình nghiên cứu và thực hiện đề tài "*Phân tích Hành vi Khách hàng & Tối ưu Bán lẻ Thương mại Điện tử bằng Học máy trên tập dữ liệu Olist*", báo cáo đã hoàn thành trọn vẹn các mục tiêu kinh doanh và kỹ thuật được đặt ra từ ban đầu. Sự kết hợp giữa tư duy phân tích định lượng và các thuật toán khai phá dữ liệu đã mang lại những góc nhìn sâu sắc, vượt ra khỏi các thống kê báo cáo thông thường.

Cụ thể, nghiên cứu đã đạt được những kết quả trọng tâm sau:

Về mặt Phân tích và Khám phá dữ liệu (EDA): Quá trình làm sạch, tích hợp và trực quan hóa dữ liệu đã bóc tách thành công những điểm nghẽn trong vận hành, từ sự sụt giảm uy tín do đối tác giao hàng trễ hẹn, đến việc xác định "giờ vàng" mua sắm và bóc tách hiệu suất thực sự của từng ngành hàng.

Về mặt Phân cụm Khách hàng: Việc chuẩn hóa dữ liệu RFM và ứng dụng thuật toán K-Means đã giải quyết được bài toán phân mảnh người dùng. Chân dung 4 nhóm khách hàng (VIP, Loyal, New/Low Spenders, Sleeping) được phác họa bằng số liệu cụ thể chính là cơ sở vững chắc để thiết kế các chiến dịch tiếp thị cá nhân hóa.

Về mặt Dự đoán Rủi ro (Churn Prediction): Việc xử lý thành công bài toán dữ liệu mất cân bằng thông qua kỹ thuật SMOTE và huấn luyện mô hình Random Forest đã tạo ra một công cụ phân loại rủi ro hiệu quả. Hệ thống hoàn toàn có thể tự động hóa việc nhận diện nhóm khách hàng sắp rời bỏ nền tảng để kịp thời triển khai các biện pháp nới giữ (Retention).

Những kết quả thu được từ đề tài này không chỉ chứng minh sức mạnh của phương pháp "Ra quyết định dựa trên dữ liệu" (Data-driven decision making) trong ngành thương mại điện tử, mà còn là minh chứng cho việc vận dụng linh hoạt kiến thức kỹ thuật vào thực tiễn. Quá trình triển khai từ khâu xử lý dữ liệu thô, thiết kế luồng xử lý đồng bộ đến việc tinh chỉnh mô hình máy học đòi hỏi sự kết hợp chặt chẽ của nền tảng Kỹ thuật Máy tính và Công nghệ Phần mềm.

Đây sẽ là bước đệm vững chắc để tiếp tục mở rộng quy mô bài toán, hướng tới việc triển khai các mô hình này lên môi trường máy chủ thực tế, tối ưu hóa kiến trúc hạ tầng và tích hợp luồng MLOps chuyên nghiệp nhằm đáp ứng yêu cầu xử lý dữ liệu theo thời gian thực (Real-time processing) của các doanh nghiệp trong tương lai.

QR CODE GITHUB



Hình 5.1. Qr code github

TÀI LIỆU THAM KHẢO

1. Nguồn dữ liệu chính: Olist (2018). *Brazilian E-Commerce Public Dataset by Olist*. Kaggle. Truy cập từ: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
2. Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
3. Hughes, A. M. (2005). *Strategic Database Marketing: The Masterplan for Starting and Managing a Profitable, Customer-Based Marketing Program*. McGraw-Hill.
4. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
5. MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281-297.
6. **Hughes, A. M.** (2005). *Strategic Database Marketing: The Masterplan for Starting and Managing a Profitable, Customer-Based Marketing Program* (3rd ed.). McGraw-Hill.
7. **Kreuzberger, D., Kühl, N., & Hirschl, S.** (2023). Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access*, 11, 31866-31879. <https://doi.org/10.1109/ACCESS.2023.3262138>
8. **Louppe, G., Wehenkel, L., Sutter, A., & Geurts, P.** (2013). Understanding variable importances in forests of randomized trees. *Advances in Neural Information Processing Systems (NeurIPS)*, 26, 431-439.
9. **MacQueen, J.** (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281-297.
10. **Olist.** (2018). *Brazilian E-Commerce Public Dataset by Olist*. Kaggle. Truy cập từ <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
11. **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E.** (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.